

Módulo 7

Aprendizaje de máquina no supervisado 4. Manifold Learning

Eduardo Espinosa Avila



Manifold Learning, Kernel PCA

Cuando tratamos con problemas de naturaleza no lineal, PCA no es una buena opción para reducir la dimensionalidad de los datos.

Para este tipo de situación existe una versión *kernelizada*, llamada KPCA.

La idea es aplicar una transformación no lineal para proyectar los datos en un espacio de dimensión superior.

$$\mathbf{x} = [x_1, x_2]^T$$

Y posteriormente aplicar PCA para proyectarlo sobre un espacio de dimensión inferior, en el que los datos sean linealmente separables.


$$\begin{matrix} \downarrow \\ \phi \\ \downarrow \end{matrix}$$

$$\mathbf{z} = [x_1^2, \sqrt{2x_1x_2}, x_2^2]^T$$

Manifolds

Un *manifold* es un espacio topológico, que localmente parece ser un espacio euclidiano en la cercanía de cada uno de sus puntos.

Para el caso del aprendizaje, en un *manifold* los datos son de dimensión baja *dentro* de espacios de alta dimensión.



$$\alpha + \beta + \gamma > 180^\circ$$

$$\alpha + \beta + \gamma = 180^\circ$$



Dominio público,
<https://commons.wikimedia.org/w/index.php?curid=1216752>

Manifolds

Por ejemplo, una hoja de papel es 2D en nuestro espacio 3D.

Reorientar o estirar la hoja dentro del espacio 3D no cambia la geometría plana de la hoja.

Estas operaciones son similares a transformaciones lineales en el espacio 3D.

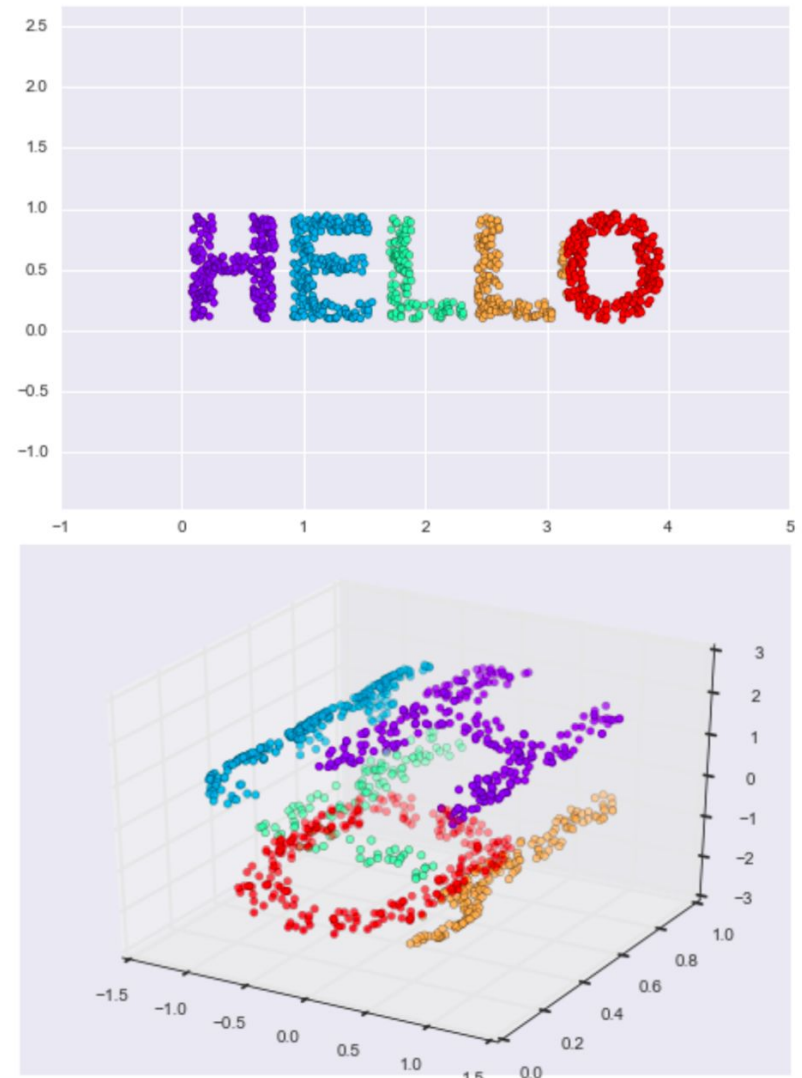


Manifolds

En cambio, doblar, enrollar o arrugar la hoja, conserva su naturaleza 2D.

Pero estas transformaciones ya no son lineales en el espacio 3D.

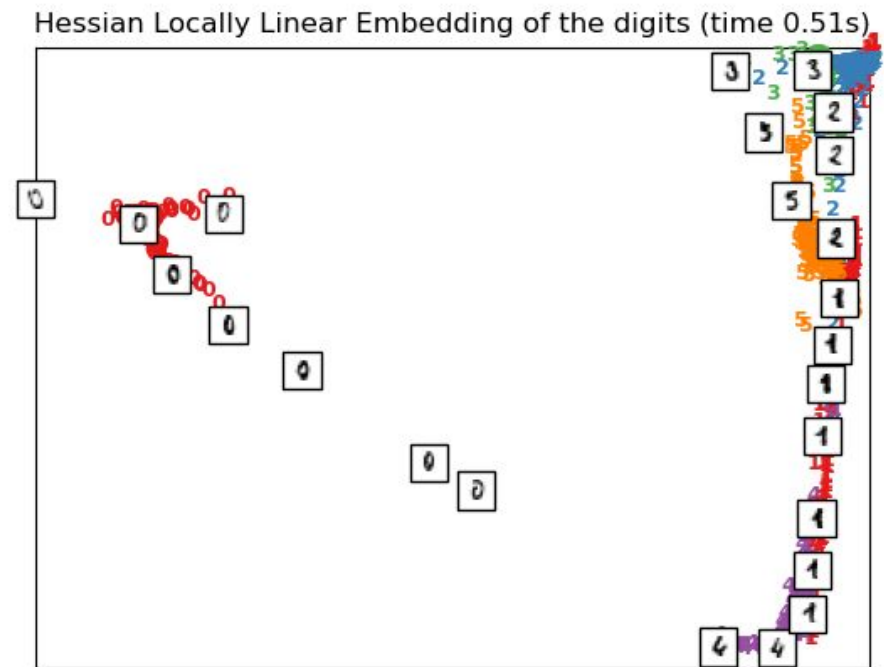
Los algoritmos de aprendizaje con *manifolds*, buscan encontrar la naturaleza 2D de la hoja, aún después de este tipo de operaciones.



Manifold Learning, Isomap

Isometric Mapping
(*isomap*) puede verse
como una extensión de
Kernel PCA.

Intenta encontrar la menor
representación dimensional,
manteniendo la distancia
geodésica entre los puntos.



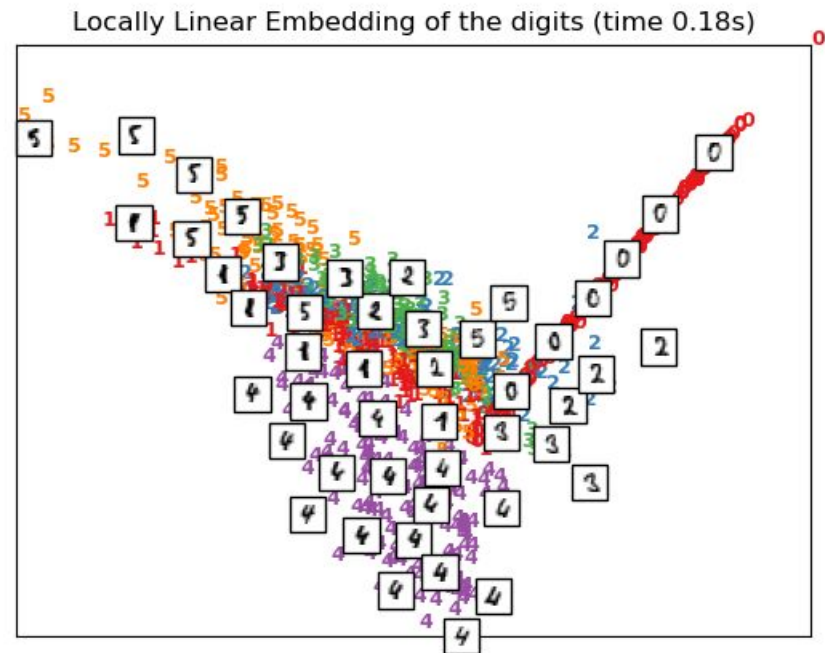
https://scikit-learn.org/stable/auto_examples/manifold/plot_lle_digits.html

Manifold Learning, Locally Linear Embedding

Locally Linear Embedding (LLE) busca la proyección de menor dimensión, manteniendo las distancias con el *vecindario local*.

Puede verse como la aplicación repetida de PCA a nivel local, que después se compara globalmente.

Al basarse en vecinos, es necesario proporcionar el número a considerar como parámetro.

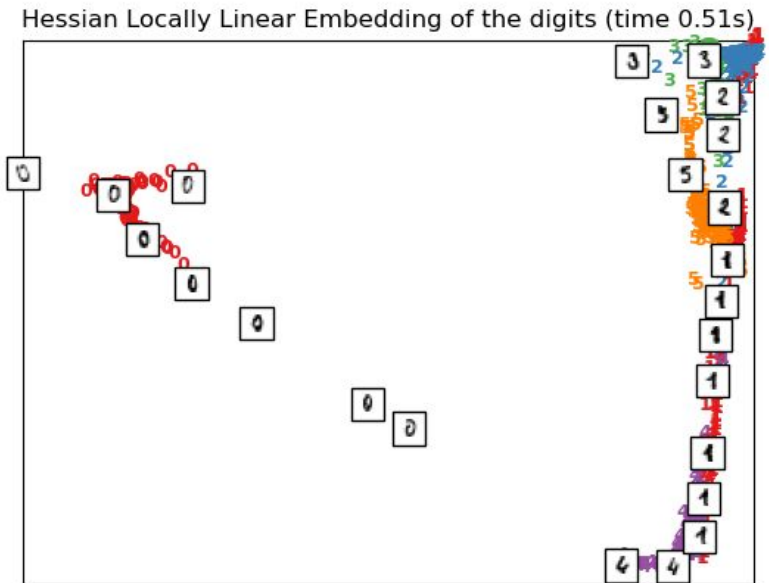


https://scikit-learn.org/stable/auto_examples/manifold/plot_lle_digits.html

Manifold Learning, Hessian LLE

LLE presenta un problema de regularización (sobreajuste), cuando el número de vecinos a considerar es mayor que el número de dimensiones de entrada.

Hessian LLE minimiza la [función hessiana](#) del manifold, en el que residen los datos.



https://scikit-learn.org/stable/auto_examples/manifold/plot_lle_digits.html

Referencias

- VanderPlas, J.
Python Data Science Handbook / Jake VanderPlas --
USA : O'Reilly Media Inc., 2017 (530 páginas)
- James McQueen, Marina Meilă, Jacob VanderPlas and Zhongyue Zhang
Megaman: Scalable Manifold Learning in Python
<https://jmlr.org/papers/volume17/16-109/16-109.pdf>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V. et al.
Scikit-learn: Machine Learning in Python -- Manifold learning
<https://scikit-learn.org/stable/modules/manifold.html>

Contacto

Dr. Eduardo Espinosa Avila

laloea@fisica.unam.mx

Tels: 5556225000 ext. 5003

Redes sociales:

<https://twitter.com/laloea>

<https://www.linkedin.com/in/eduardo-espinosa-avila-84b95914a/>