1a Emisión

Módulo 8

Introducción al Deep Learning

Redes recurrentes

Instructor: Gibran Fuentes Pineda

DGTIC
UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
Dirección General de Cómputo y de Tecnologías de información y Comunicación
Dirección de Docencia en TIC
Educación Continua
1971 - 2021

Objetivo del tema

- Conocer los componentes básicos y comprender el funcionamiento de las redes recurrentes, así como las estrategias para entrenarlas.

Sub-temas

7.1 Motivación
7.2 Unidad recurrente básica
7.3 Long-short term memory (LSTM)
7.4 Gated recurrent unit (GRU)
7.5 Arquitecturas de redes recurrentes
7.6 Algoritmo de retropropagación de errores para redes recurrentes
7.7 Ejemplo práctico: series de tiempo

Motivación: secuencias de palabras

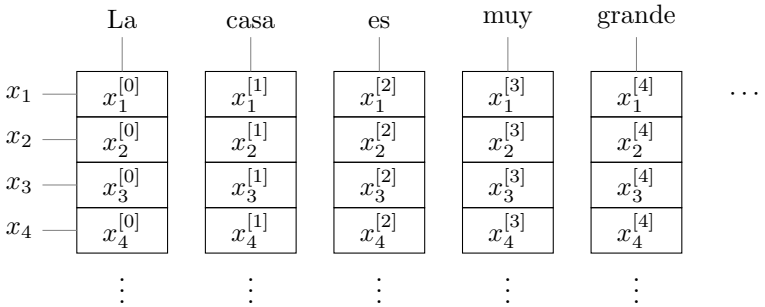

Unidad recurrente básica

- Capas con retro-alimentación en sus conexiones
  1. Entradas en tiempo t ($\mathbf{x}^{[t]}$)
  2. Estado en tiempo t ($\mathbf{h}^{[t]}$)

$$\mathbf{h}^{[t+1]} = \phi\left(\mathbf{W}_h \cdot \underbrace{\left[\mathbf{h}^{[t]}, \mathbf{x}^{[t]}\right]}_{\text{Concatenación}} + \mathbf{b}_h\right)$$
$$= \phi\left(\mathbf{W}_{hh} \cdot \mathbf{h}^{[t]} + \mathbf{W}_{hx} \cdot \mathbf{x}^{[t]} + \mathbf{b}_h\right)$$

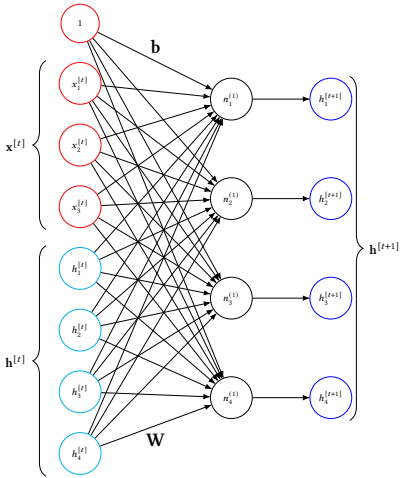

Unidad recurrente básica: diagrama de celda

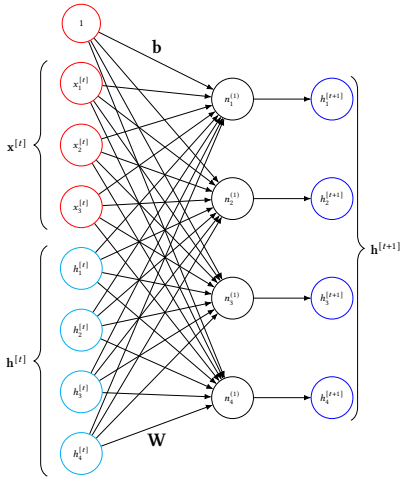

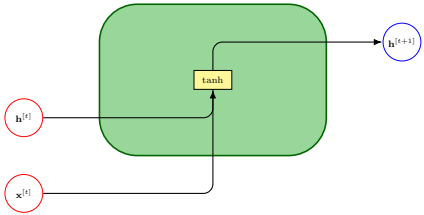

Unidad recurrente básica: despliegue

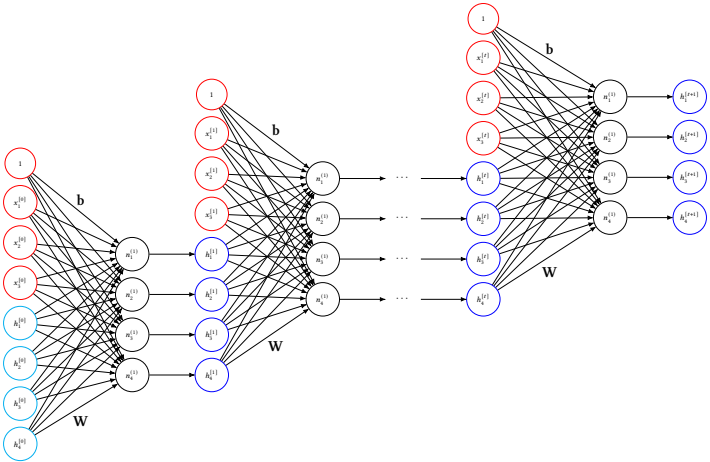

Unidad recurrente básica: despliegue de celdas

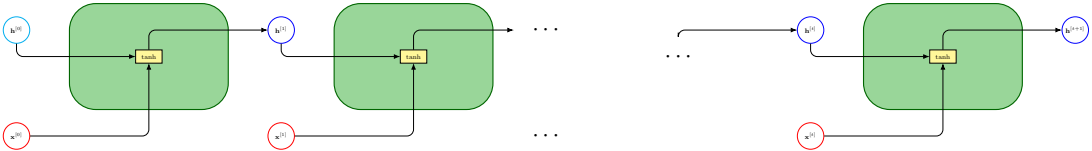

Modelando dependencias a corto plazo

- En teoría una red recurrente básica puede modelar dependencias a corto y largo plazo
  - Siegelmann y Sontag mostraron que las redes recurrentes son Turing completas[1]

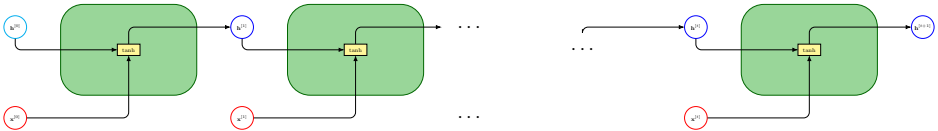

[1] Siegelmann and Sontag. On The Computational Power Of Neural Nets, 1995.

El problema de la memoria a largo plazo

- En práctica es muy difícil entrenarlas para tareas con dependencias a largo plazo

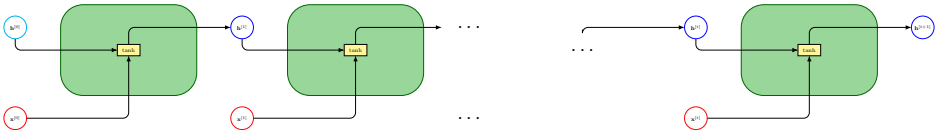

Long-short term memory (LSTM)

- Agregan elementos internos a la celda básica que permiten capturar dependencias a corto y largo plazo

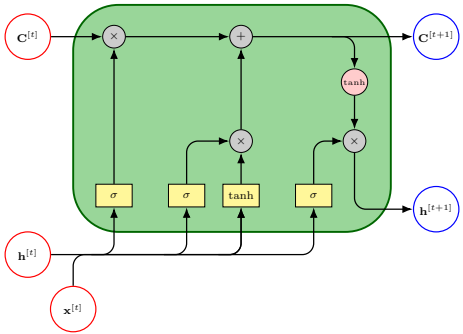

Long-short term memory (LSTM): salida de la capa anterior

- Agrega o elimina información del estado $\mathbf{C}^{[t]}$ a partir de la entrada actual $\mathbf{x}^{[t+1]}$ y la salida anterior $\mathbf{h}^{[t]}$

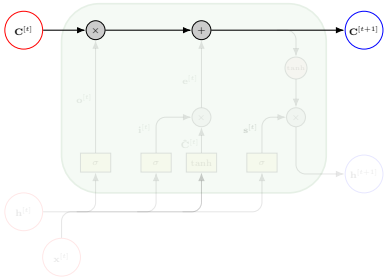

Long-short term memory (LSTM): compuerta de olvido

- Determina qué olvidar del estado $\mathbf{C}^{[t]}$ y en qué proporción a partir de la entrada actual $\mathbf{x}^{[t+1]}$ y la salida anterior $\mathbf{h}^{[t]}$

$$\mathbf{f}^{[t+1]} = \sigma\left(\mathbf{W}_f \cdot \left[\mathbf{h}^{[t]}, \mathbf{x}^{[t+1]}\right] + \mathbf{b}_f\right)$$

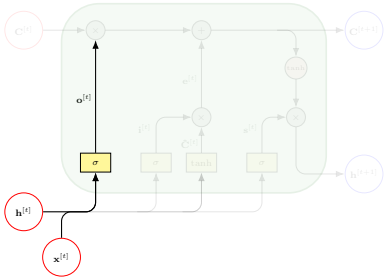

Long-short term memory (LSTM): computerta de entrada

- Determina qué agregar al estado $\mathbf{C}^{[t]}$ y en qué proporción a partir de la entrada actual $\mathbf{x}^{[t+1]}$ y el estado oculto anterior $\mathbf{h}^{[t]}$

$$\mathbf{i}^{[t+1]} = \sigma\left(\mathbf{W}_i \cdot \left[\mathbf{h}^{[t]}, \mathbf{x}^{[t+1]}\right] + \mathbf{b}_i\right)$$
$$\hat{\mathbf{C}}^{[t+1]} = \tanh\left(\mathbf{W}_C \cdot \left[\mathbf{h}^{[t]}, \mathbf{x}^{[t+1]}\right] + \mathbf{b}_C\right)$$
$$\mathbf{e}^{[t+1]} = \mathbf{i}^{[t+1]} \odot \hat{\mathbf{C}}^{[t+1]}$$

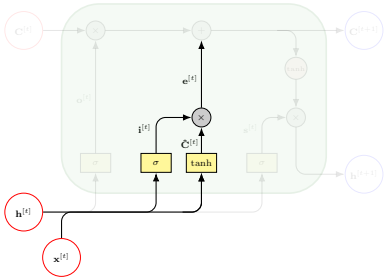

Long-short term memory (LSTM): nuevo estado

- El nuevo estado $\mathbf{C}^{[t+1]}$ se obtiene como una combinación del estado $\mathbf{C}^{[t+1]}$, la salida $\mathbf{f}^{(t)}$ de la compuerta de olvido y la salida $\mathbf{e}^{[t+1]}$ de la compuerta de entrada

$$\mathbf{C}^{[t+1]} = \mathbf{f}^{[t+1]} \odot \mathbf{C}^{[t]} + \mathbf{e}^{[t+1]}$$

donde $\odot$ denota el producto de Hadamard

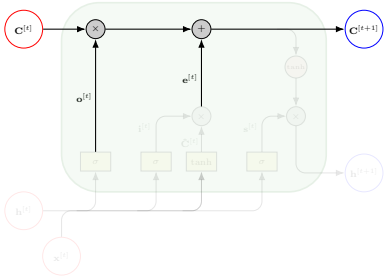

Long-short term memory (LSTM): computerta de salida

- El siguiente estado oculto $\mathbf{h}^{[t+1]}$ se obtiene como una combinación de la entrada actual $\mathbf{x}^{[t+1]}$, el estado oculto anterior $\mathbf{h}^{[t]}$ y el nuevo estado $\mathbf{C}^{[t+1]}$

$$\mathbf{o}^{[t+1]} = \sigma\left(\mathbf{W}_o \cdot \left[\mathbf{h}^{[t]}, \mathbf{x}^{[t+1]}\right] + \mathbf{b}_o\right)$$

$$\mathbf{h}^{[t+1]} = \mathbf{o}^{[t+1]} \odot \tanh\left(\mathbf{C}^{[t+1]}\right)$$

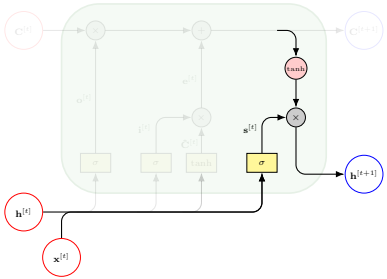

Gated recurrent unit (GRU)

- Combina compuertas de olvido y entrada en una sóla

$$\mathbf{z}^{[t+1]} = \sigma\left(\mathbf{W}_z \cdot \left[\mathbf{h}^{[t]}, \mathbf{x}^{[t+1]}\right] + \mathbf{b}_z\right)$$

$$\mathbf{r}^{[t+1]} = \sigma\left(\mathbf{W}_r \cdot \left[\mathbf{h}^{[t]}, \mathbf{x}^{[t+1]}\right] + \mathbf{b}_r\right)$$

$$\tilde{\mathbf{h}}^{[t+1])} = \tanh\left(\mathbf{W}_h \cdot \left[\mathbf{r}^{[t+1]} \odot \mathbf{h}^{[t]}, \mathbf{x}^{[t+1]}\right] + \mathbf{b}_h\right)$$

$$\mathbf{h}^{[t+1]} = \left(1 - \mathbf{z}^{[t+1]}\right) \odot \mathbf{h}^{[t]} + \mathbf{z}^{[t+1]} \odot \tilde{\mathbf{h}}^{[t+1]}$$

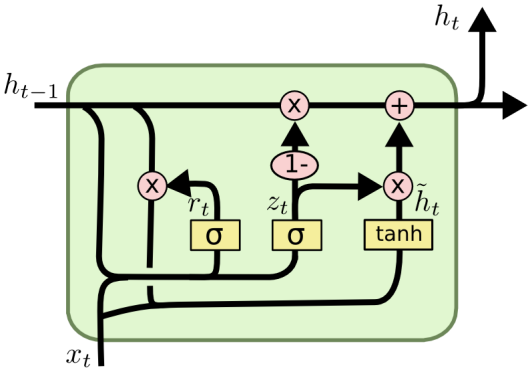

Arquitecturas de redes recurrentes

- Contienen celdas recurrentes en conjunto con otras capas
- La salida de una celda alimenta otras capas u otras celdas
- Por ejemplo, para predecir el siguiente símbolo en un texto con una celda recurrente básica, a la salida podemos agregar una capa densa con función de activación *softmax*

$$\hat{\mathbf{y}}^{[t+1]} = softmax\left(\mathbf{W}_y \cdot \mathbf{h}^{[t+1]} + \mathbf{b}_y\right)$$

Arquitecturas de redes recurrentes: ejemplo

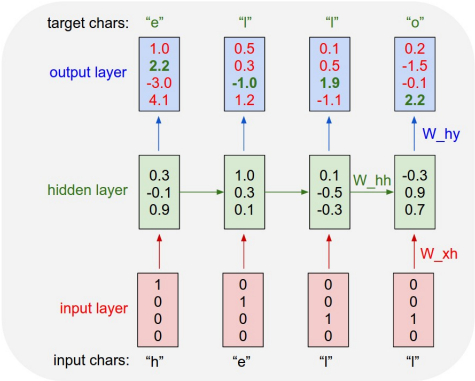

Imagen tomada de Karpathy 2015 (http://karpathy.github.io/2015/05/21/rnn-effectiveness/)

Arquitecturas de redes recurrentes: tareas de uno a uno

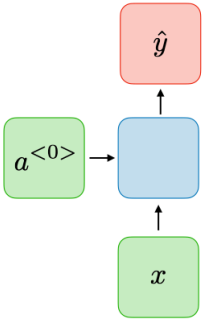

Imagen tomada de Amidi. Recurrent Neural Networks cheatsheet

Arquitecturas de redes recurrentes: tareas de uno a muchos

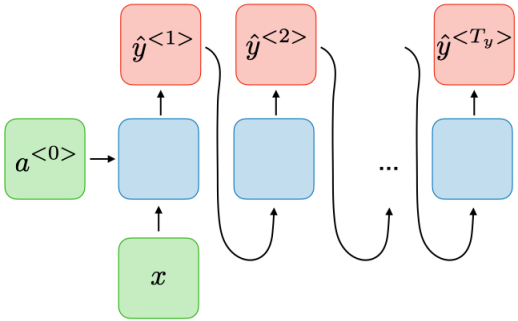

Imagen tomada de Amidi. Recurrent Neural Networks cheatsheet

Arquitecturas de redes recurrentes: tareas de muchos a uno

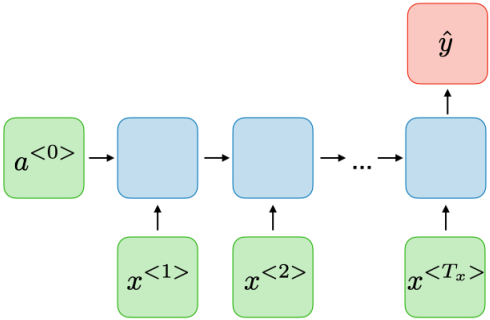

Imagen tomada de Amidi. Recurrent Neural Networks cheatsheet

Arquitecturas de redes recurrentes: tareas de muchos a muchos

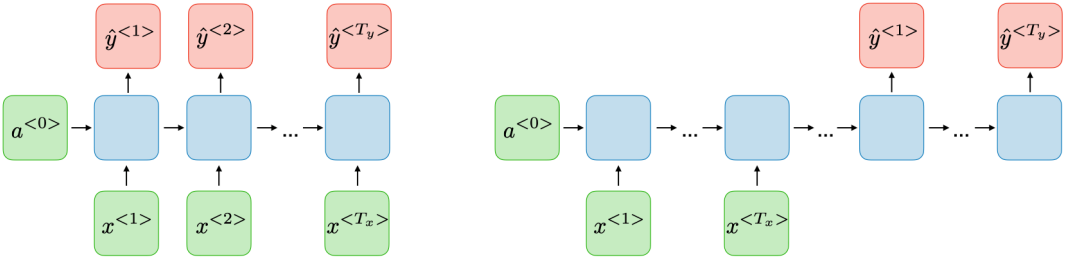

Imagen tomada de Amidi. Recurrent Neural Networks cheatsheet

Arquitecturas de redes recurrentes: LSTM/GRU bidireccional

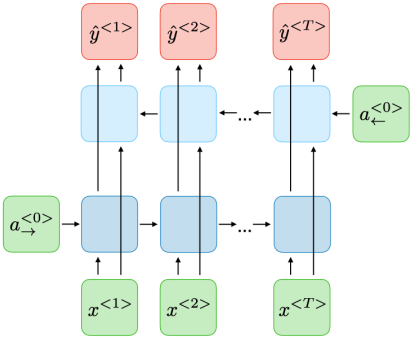

Imagen tomada de Amidi. Recurrent Neural Networks cheatsheet

Arquitecturas de redes recurrentes: celdas apiladas

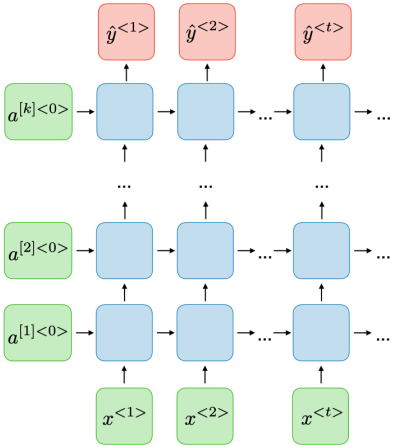

Imagen tomada de Amidi. Recurrent Neural Networks cheatsheet

Algoritmo de retropropagación de errores para redes recurrentes

- Pérdida en el tiempo

$$\mathcal{L}\left(\hat{\mathbf{y}}, \mathbf{y}\right) = \sum_{t=1}^{T} \mathcal{L}(\hat{\mathbf{y}}^{[t]}, \mathbf{y}^{[t]})$$

- Retropropagación

$$\frac{\partial \mathcal{L}^{[T]}}{\partial \boldsymbol{\theta}} = \sum_{t=1}^{T} \frac{\partial \mathcal{L}^{[t]}}{\partial \boldsymbol{\theta}}$$

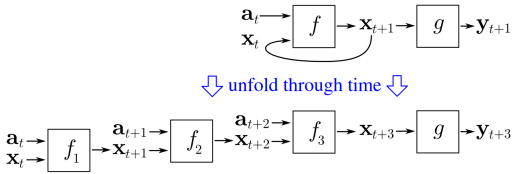

Imagen tomada de Wikipedia (https://en.wikipedia.org/wiki/Backpropagation_through_time)

Referencias

- Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. (2021). Dive into deep learning. Capítulos 8 y 9. Disponible en http://www.d2l.ai/.
- Murphy, K. P. (2022). Probabilistic Machine Learning: An introduction. MIT Press. Capítulo 15. Disponible en https://probml.github.io/pml-book/book1.html.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT press. Capítulo 10. Disponible en https://www.deeplearningbook.org/.
- Amidi, A. & Amidi, S. Recurrent Neural Networks cheatsheet. Disponible en https://stanford.edu/ shervine/teaching/cs-230/cheatsheet-recurrent-neural-networks.
- Olah, C. (2015). Understanding LSTM Networks. Disponible en https://colah.github.io/posts/2015-08-Understanding-LSTMs/.
- Karpathy A. (2015). The Unreasonable Effectiveness of Recurrent Neural Networks. Disponible en http://karpathy.github.io/2015/05/21/rnn-effectiveness/.

Contacto

Gibran Fuentes Pineda

Investigador Asociado "C", IIMAS, UNAM

gibranfp@unam.mx

LinkedIn: @gibranfuentespineda