

**3<sup>a</sup>**  
**Emisión**

# DATA SCIENCE

## Módulo 08

### Modelos generativos de Deep Learning

*Edgar Morales Palafox*



**UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO**  
Dirección General de Cómputo y de Tecnologías de información y Comunicación  
Dirección de Docencia en TIC



Educación  
Continua  
1971 - 2021

# Objetivo

El participante identificará los componentes y funcionamiento de los autocodificadores variacionales y las redes generativas antagónicas, así como estrategias para entrenarlas.


# Contenido

- Autocodificadores variacionales.
- Redes generativas antagónicas (GAN).
- Ejemplo práctico: generación de imágenes de cuartos.

# Autocodificadores variacionales

Los autocodificadores variacionales son un tipo de redes neuronales compuestas de dos partes, casi dos redes neuronales por si mismas:

- La red **codificador**: que toma un dato de entrada, normalmente una fotografía, es decir, un vector de muy alta dimensionalidad, y da como resultado un vector de mucha más baja dimensión que contiene, de alguna manera, ciertas características (bordes, ángulos, formas) que resumen y definen la imagen original. Un codificador que, en el caso de imágenes se suele basar en redes de convolución.
- La red **decodificador**: que toma como entrada un vector de baja dimensionalidad, con las características que definen, según el ejemplo anterior, una fotografía. Y como salida, debe producir esa misma fotografía. Y un decodificador que, en el caso de imágenes, se suele basar en redes de convolución traspuestas.



Durante el entrenamiento, se busca que la diferencia (cuantificada mediante una **función de pérdida**) entre la fotografía de entrada y la fotografía de salida, sea lo menor posible.

Si se consigue, tendremos un codificador capaz de captar las características esenciales de la fotografía y un decodificador capaz de construir una fotografía con base a esas características esenciales, una fotografía que, además, de alguna forma tiene el mismo estilo, la misma naturaleza que la original.

Ese mismo estilo, esa misma naturaleza, expresado de forma matemática quiere decir que ambas fotografías, la de entrada y la de salida, responden a una misma **distribución de probabilidad subyacente**.

# ¿Cómo se construye ahora una fotografía completamente nueva?

Una vez que ya la red está entrenada, nos olvidamos del codificador y nos centramos en el decodificador. No tenemos más que ponerle como entrada a ese decodificador un vector de características, un vector que, ahora, podemos haber generado de manera absolutamente aleatoria.

El decodificador dará como resultado una fotografía realista, del mismo estilo y naturaleza (misma distribución de probabilidad subyacente) que las usadas en el entrenamiento... pero con un contenido completamente nuevo.




# Aplicaciones de los autoencoders

La representación compacta obtenida con el Autoencoder es útil por ejemplo para eliminar ruido en imágenes o para detectar anomalías en una serie de datos:

Eliminación de ruido



Detección de anomalías





# Redes Generativas Antagónicas GANs

Red neuronal que genera cosas a partir del aprendizaje de su adversario

La idea **radica en enfrentar dos redes neuronales que compiten en un constante juego de suma cero** (la ganancia o pérdida de una de las redes se compensa con la ganancia o pérdida de la opuesta).



Imagen tomada de: [https://www.cs.us.es/~fsancho/ficheros/IAML/GAN\\_JMVerde.pdf](https://www.cs.us.es/~fsancho/ficheros/IAML/GAN_JMVerde.pdf)

# ¿Cómo funcionan las GANs?

**Una de las redes, es la generativa**, va produciendo muestras de aquello que queramos crear (imágenes, textos, sonidos...); ese primer intento será fallido.

**La segunda red, es la discriminadora**, analiza el material producido por la red generativa y determina si se ajusta a lo que está buscando: es decir, hablando en términos técnicos, decide si cada instancia de datos que revisa pertenece o no al conjunto de datos de entrenamiento.

Si la red generativa no es capaz de 'pasar' ese material como auténtico, lo descartará, notificando a la generativa **en qué medida se ha acercado a esa referencia deseada** (su modelo de entrenamiento). Eso fuerza a la red generativa a realizar un nuevo intento.

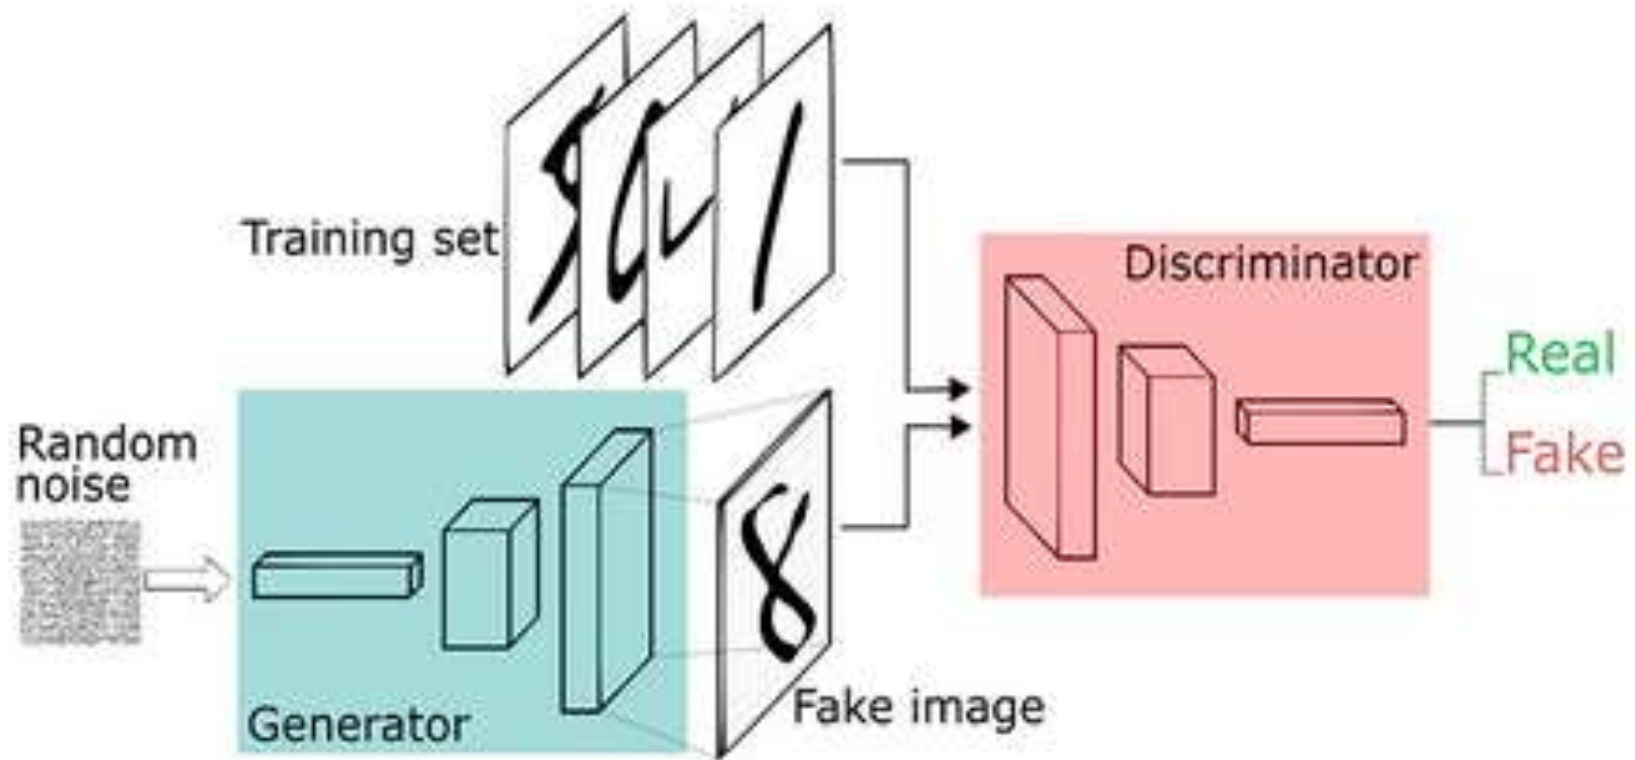


Imagen tomada de: [https://www.cs.us.es/~fsancho/ficheros/IAML/GAN\\_JMVerde.pdf](https://www.cs.us.es/~fsancho/ficheros/IAML/GAN_JMVerde.pdf)

Puede haber **cientos, miles o millones de intentos antes de que la red discriminadora acepte el resultado** ofrecido por su rival. Mientras tanto, rechazo tras rechazo, la red generativa habrá ido 'aprendiendo' qué es lo que busca la discriminadora, quien a su vez le habrá ido guiando con la información que aportaba con sus porcentajes de acierto.

# Ejemplo

<https://colab.research.google.com/drive/1uECkwEftthCDwQDY4t4AXMFUt0XdRi2qe#scrollTo=U9RczsZun0yG>

# Referencias

- Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. (2021). Dive into deep learning. Disponible en <http://www.d2l.ai/>.
- Murphy, K. P. (2022). Probabilistic Machine Learning: An introduction. MIT Press. Disponible en <https://probml.github.io/pml-book/book1.html>.
- Bloem, P. (2019). Transformers from scratch. Disponible en <http://peterbloem.nl/blog/transformers>.

# Contacto

Edgar Morales Palafox

*Doctor en Ciencias de la Computación*

Edgar\_morales\_p@yahoo.com.mx

Tels: (55 3104 1600)