



## **Objetivo**

El participante identificará las diferentes etapas que conforman el modelo CRISP-DM.



### Contenido

- 1. Comprensión del negocio
- 2. Comprensión de los datos
- 3. Preparación de los datos
- 4. Modelado
- 5. Evaluación
- Implantación (despliegue y explotación)



**CRISP-DM**, son las siglas de Cross-Industry Standard Process for Data Mining. Es un método probado para orientar sus trabajos de minería de datos.

Como **metodología**, incluye descripciones de las fases normales de un proyecto, las tareas necesarias en cada fase y una explicación de las relaciones entre las tareas.

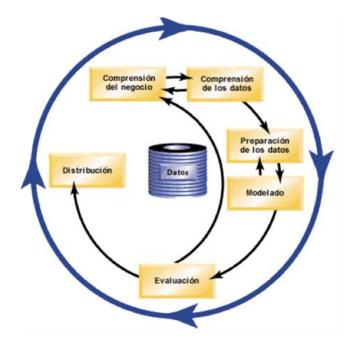
Como **modelo de proceso**, CRISP-DM ofrece un resumen del ciclo vital de minería de datos.



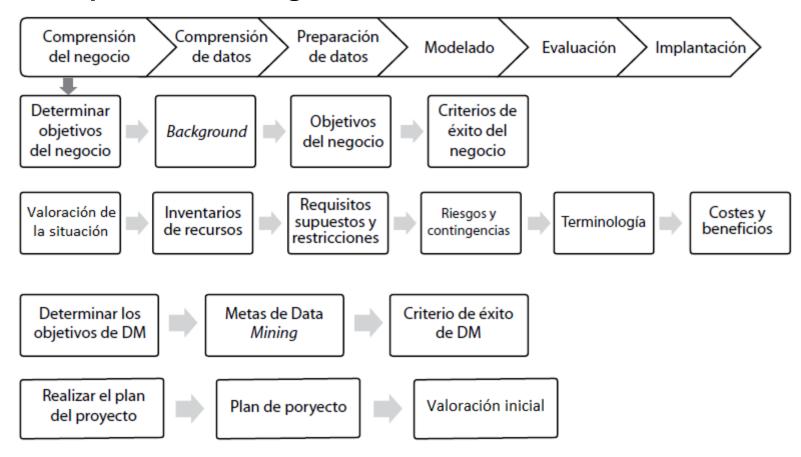
gmc

El ciclo vital del modelo contiene seis fases con flechas, que indican las dependencias más importantes y frecuentes entre fases. La secuencia de las fases no es estricta. De hecho, la mayoría de los proyectos avanza y retrocede entre fases si es necesario.

- 1. Comprensión del negocio
- 2. Comprensión de los datos
- 3. Preparación de los datos
- 4. Modelado
- 5. Evaluación
- 6. Despliegue y explotación







**Figura** Fase de comprensión del negocio. Tomado de CRISP-DM 1.0 Step-by-Step Data Mining Guide (P. Chapman et al.), 2000.



La primera etapa del modelo CRISP-DM es la "Comprensión del negocio". Esta etapa se enfoca en entender los objetivos y los requerimientos del proyecto desde una perspectiva empresarial, para convertir ese conocimiento en la definición de un problema de minería de datos, con un plan preliminar para la consecución de esos objetivos.

Esta etapa se conforma de los siguientes pasos:

- 1. Determinar los objetivos del negocio
- 2. Valoración de la situación
- 3. Determinación de los objetivos de minería de datos
- 4. Producción de un plan de proyecto



#### 1. Determinar los objetivos del negocio

La primera tarea es obtener la máxima información posible de los objetivos comerciales de la minería de datos. Es posible que esta tarea no sea tan fácil como parece, pero puede reducir los futuros riesgos, clarificando los problemas, los objetivos y los recursos.

La metodología CRISP-DM proporciona una forma estructurada de alcanzar estos objetivos.

#### Lista de tareas

- 1.1 Compilación de la información de la empresa
- 1.2 Definición de los objetivos comerciales
- 1.3 Criterios de rendimiento comercial



#### 1.1 Compilación de la información de la empresa

Deberá examinar su situación comercial, para encontrar respuestas reales a las preguntas que puedan tener un impacto en el resultado del proyecto de minería de datos.

- La 1.1 Compilación de la información de la empresa, se subdivide en las siguientes tareas:
- 1.1.1 Determinar la estructura de la organización
- 1.1.2 Describir el área problemática
- 1.1.3 Describir la solución actual



#### 1.1.1 Determinar la estructura de la organización

- Desarrolle gráficos de la organización para ilustrar divisiones corporativas, departamentos y grupos de proyectos. Asegúrese de incluir nombres y responsabilidades de los directivos
- Identifique individuos clave de la organización
- Identifique un patrocinador interno que proporcionará apoyo financiero y/o la experiencia en el dominio
- Determine si existe un comité de dirección y procure una lista de miembros
- Identifique las unidades comerciales que se verán afectadas por el proyecto de minería de datos



#### 2. Valoración de la situación.

Ahora que ha definido un objetivo comercial claro, es hora de realizar una valoración de su situación actual.

El numeral 2. Valoración de la situación, se subdivide en las siguientes tareas:

- 2.1 Inventario de recursos
- 2.2 Requisitos, supuestos y restricciones
- 2.3 Riesgos y contingencias
  - 2.3.1 Programación
  - 2.3.2 Financieros
  - 2.3.3 Datos
  - 2.3.4 Resultados
- 2.4 Terminología
- 2.5 Análisis de costes/beneficios



#### 3. Determinación de los objetivos de minería de datos

Como puede comprobar, la tecnología y la empresa deben ir de la mano para que el proyecto de minería de datos sea efectivo. Cuando trabaje con analistas comerciales y de datos para definir una solución técnica al problema comercial, recuerde que los objetivos deben ser concretos.

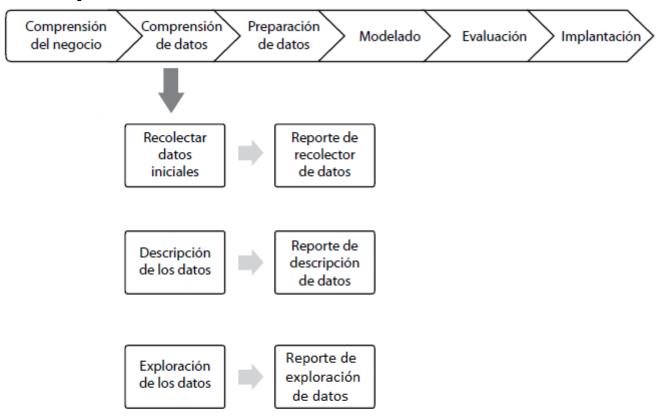
- ✓ Describa el tipo de problema de minería datos, como conglomerado, pronóstico o clasificación
- ✓ Documente objetivos técnicos, utilizando unidades específicas de tiempo, como predicciones con una validez de tres meses
- ✓ Si es posible, proporcione datos reales para resultados deseados, como producir resultados de abandono para el 80% de los clientes actuales



### 4. Plan de proyecto de muestra

Fase	Tiempo	Recursos	Riesgos
Comprensión del negocio	1 semana	Todos los analistas	Cambio económico
Comprensión de los datos	3 semanas	Todos los analistas	Problemas de datos, problemas tecnológicos
Preparación de los datos	5 semanas	Asesor de minería de datos, tiempo de análisis de base de datos	Problemas de datos, problemas tecnológicos
Modelado	2 semanas	Asesor de minería de datos, tiempo de análisis de base de datos	Problemas de tecnología, incapacidad para encontrar un modelo adecuado
Evaluación	1 semana	Todos los analistas	Cambio económico, incapacidad para implementar resultados
Distribución	1 semana	Asesor de minería de datos, tiempo de análisis de base de datos	Cambio económico, incapacidad para implementar resultados





**Figura** Fase de comprensión de los datos. Tomado de CRISP-DM 1.0 Step-by-Step Data Mining Guide (P. Chapman et al.), 2000.



La fase de comprensión de datos de CRISP-DM implica estudiar más de cerca los datos disponibles de minería. Este paso es esencial para evitar problemas inesperados durante la siguiente fase (preparación de datos), que suele ser la más larga de un proyecto.

La comprensión de datos implica acceder a ellos y explorarlos con la ayuda de tablas y gráficos, que se pueden organizar en IBM® SPSS® Modeler, utilizando la herramienta de proyectos CRISP-DM.

De esta forma podrá determinar la calidad de los datos y describir los resultados de estos pasos en la documentación del proyecto.



Esta etapa se conforma de los siguientes pasos:

- 1. Recopilación de datos iniciales
  - Datos existentes
  - Datos adquiridos
  - Datos adicionales
- 2. Descripción de los datos
  - Cantidad de datos
  - Tipos de valores
  - Esquemas de codificación
- 3. Exploración de datos

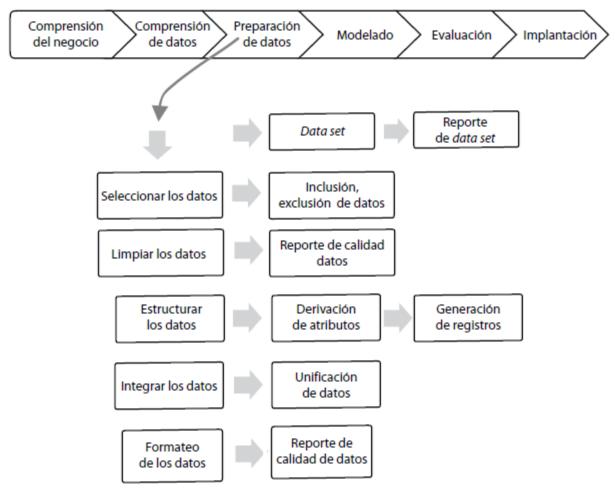
Estos análisis pueden ayudarle a describir los objetivos de minería de datos, generados durante la fase de comprensión comercial.



El **informe de exploración de datos** debe responder a las cuestiones siguientes:

- ¿Qué tipo de hipótesis sobre los datos ha formulado?
- ¿Qué atributos parecen ser prometedores de cara a futuros análisis?
- ¿Ha realizado exploraciones que revelen nuevas características de los datos?
- ¿En qué forma han cambiado estas exploraciones su hipótesis inicial?
- ¿Puede identificar subconjuntos concretos de datos para un uso posterior?
- Vuelva a comprobar sus objetivos de minería de datos.
- ¿Esta exploración ha modificado sus objetivos?





**Figura** Fase de preparación de los datos. Tomado de CRISP-DM 1.0 Step-by-Step Data Mining Guide (P. Chapman et al.), 2000.



La preparación de datos es uno de los aspectos más importantes y con frecuencia lo que más tiempo exige en la minería de datos. De hecho, se estima que la preparación de datos suele llevar entre el 50 y 70% del tiempo y esfuerzo de un proyecto.

Esta etapa se conforma de los siguientes pasos:

- 1. Selección de datos
- 2. Inclusión o exclusión de datos
- 3. Limpieza de datos
- 4. Construcción de nuevos datos
- 5. Integración de datos
- 6. Formato de datos



#### 1. Selección de datos

En función de la recopilación de datos inicial realizada en la fase CRISP-DM anterior, ahora puede comenzar a seleccionar los datos relevantes a sus objetivos de minería de datos. De forma general, existen dos formas de seleccionar datos:

- Selección de elementos (filas) implica la toma de decisiones, como las cuentas, productos o clientes que se van a incluir.
- Selección de atributos o características (columnas) implica la toma de decisiones sobre el uso de características, como la cantidad de las transacciones o los ingresos por hogar.



#### 2. Inclusión o exclusión de datos

Aspectos a considerar en la inclusión o exclusión de datos:

- ¿Existe un atributo relacionado con sus objetivos de minería de datos?
- ¿La calidad de un conjunto o atributo de datos concreto excluye la validez de los resultados?
- ¿Puede recuperar estos datos?
- ¿Existen limitaciones acerca del uso de campos concretos como *género* o *raza*?



#### 3. Limpieza de datos

La limpieza de datos implica observar más de cerca los problemas en los datos que ha seleccionado para incluir en el análisis. Existen diferentes formas de limpiar los datos, utilizando los nodos de registro y de operaciones con campos de IBM® SPSS® Modeler.

Problema de datos	Solución posible	
Datos perdidos	Excluya las filas o características. O cumpliméntelas con un valor estimado.	
Errores de datos	Utilice recursos lógicos para descubrir errores manuales y corríjalos. O, excluya las características	
Incoherencias de codificación	Decida un esquema de codificación simple y convierta y sustituya los valores.	
Metadatos ausentes o erróneos	Examine manualmente los campos sospechosos y compruebe el significado correcto.	







#### 4. Construcción de nuevos datos

Con frecuencia, necesitará construir nuevos datos.

Por ejemplo, puede ser de gran utilidad crear una nueva columna con la adquisición de una garantía ampliada en cada transacción. Este nuevo campo, garantía\_adquirida, se puede generar fácilmente utilizando un nodo Marcas en IBM® SPSS® Modeler.

Existen dos formas de construir nuevos datos:

- Derivación de atributos (columnas o características)
- Generación de registros (filas)



#### 5. Integración de datos

No es raro disponer de varios orígenes de datos para el mismo conjunto de cuestiones comerciales.

Existen dos métodos básicos para integrar los datos:

- La fusión de datos implica unir dos conjuntos de datos con registros similares, pero con atributos diferentes. Los datos se fusionan utilizando el mismo identificador clave en cada registro. Los datos resultantes aumentan las columnas o las características.
- La adición de datos implica integrar dos o más conjuntos de datos con atributos similares, pero con registros diferentes. Los datos se integran en función de los campos similares (como el nombre de producto o la longitud del contrato).



#### 6. Formato de datos

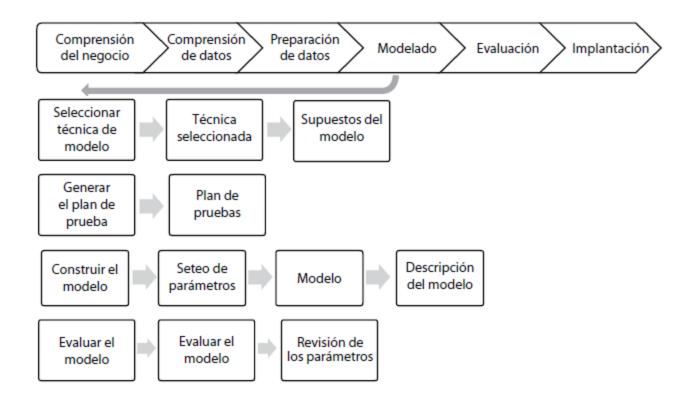
Como paso final antes de la construcción del modelo, es muy útil comprobar si algunas técnicas requieren aplicar un formato concreto o la clasificación de los datos.

Por ejemplo, no es extraño que un algoritmo de secuencia requiera que los datos estén clasificados de forma previa antes de ejecutar el modelo. Incluso, si el modelo puede ejecutar la clasificación de forma automática, puede ahorrar tiempo si utiliza un nodo Ordenar antes del modelado.

Considere las siguientes cuestiones cuando aplique formato a los datos:

- ¿Qué modelos ha planeado utilizar?
- ¿Estos modelos requieren un formato de datos o una clasificación concreta?





**Figura** Fase de modelado. Tomado de CRISP-DM 1.0 Step-by-Step Data Mining Guide (P. Chapman et al.), 2000.



Este es el punto donde todo el duro trabajo anterior comienza a tener sentido. Los datos que ha preparado se incorporan a las herramientas analíticas y los resultados comenzarán a arrojar algo de luz al problema planteado en Comprensión del negocio.

El modelado se suele ejecutar en múltiples iteraciones. Normalmente, los analistas de datos ejecutan varios modelos, utilizando los parámetros por defecto y ajustan los parámetros o vuelven a la fase de preparación de datos para las manipulaciones necesarias por su modelo.



Esta etapa se conforma de los siguientes pasos:

- 1. Selección de las técnicas de modelado correctas
- 2. Generación de un diseño de comprobación
- 3. Generación de los modelos
- 4. Evaluación del modelo



#### 1. Selección de las técnicas de modelado correctas

Aunque pueda tener algunos conocimientos acerca de los tipos de modelado, que sean los más adecuados para las necesidades de su organización, es el momento de tomar la decisión de los tipos de modelado que se van a utilizar. La determinación del modelado más adecuado se basará en las siguientes consideraciones:

- Los tipos de datos disponibles para la minería. Por ejemplo, ¿los campos de interés son categóricos (simbólicos)?
- Sus objetivos de minería de datos. ¿Sólo quiere tener un mejor conocimiento de los almacenes de datos transaccionales y descubrir patrones de compras interesantes?



- 1. Selección de las técnicas de modelado correctas
- Requisitos específicos de modelado. ¿Necesita el modelo un tipo o un tamaño de datos concreto? ¿Necesita un modelo con unos resultados fácilmente presentables?



#### 2. Generación de un diseño de comprobación

Como paso final antes de generar el modelo, debe volver a tener en cuenta cómo se comprobarán los resultados del modelo. Existen dos partes para generar un diseño de comprobación global:

- Descripción de los criterios de "bondad" de un modelo
- Definición de los datos en los que se comprobarán estos criterios

La **bondad** de un modelo se puede medir de varias formas. Para **modelos supervisados**, como C5.0 y C&R Tree, las mediciones de bondad suelen calcular la tasa de error de un modelo concreto. Para **modelos no supervisados**, como redes de conglomerados de Kohonen, las mediciones pueden incluir criterios como facilidad de interpretación, distribución o el tiempo de procesamiento necesario.



#### 3. Generación de los modelos

Se ejecuta la técnica seleccionada sobre los datos preparados para generar uno o más modelos.

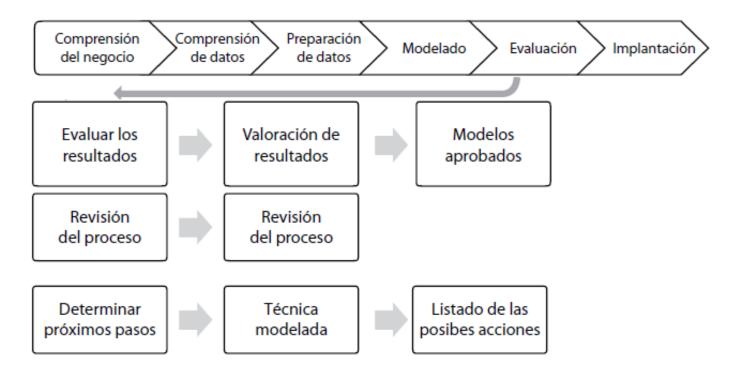
Todas las técnicas del modelado tienen un conjunto de parámetros que determinan las características del modelo por generar. La tarea de selección de los mejores parámetros es iterativa, basada en los resultados generados. Estos deben ser interpretados y su rendimiento, justificado.

#### 4. Evaluación del modelo

Se deben interpretar los modelos de acuerdo con el conocimiento del dominio y los criterios de éxitos preestablecidos.



### e. Evaluación



**Figura** Fase de evaluación. Tomado de CRISP-DM 1.0 Step-by-Step Data Mining Guide (P. Chapman et al.), 2000.



#### e. Evaluación

En este punto, habrá completado la mayor parte de su proyecto de minería de datos. También habrá determinado, en la fase de modelado, que los modelos son técnicamente correctos y efectivos en función de los **criterios de rendimiento de minería de datos** que ha definido previamente.

Sin embargo, antes de continuar, debe evaluar los resultados de sus esfuerzos, utilizando los **criterios de rendimiento comercial** establecidos al inicio del proyecto. Es la clave para asegurar que su organización pueda utilizar los resultados que ha obtenido. La minería de datos produce dos tipos de resultados:

- Los modelos finales seleccionados en la fase anterior de CRISP-DM
- Las conclusiones o interferencias obtenidas de los modelos y del proceso de minería de datos. Reciben el nombre de descubrimientos



#### e. Evaluación

Esta etapa se conforma de los siguientes pasos:

- 1. Evaluación de los resultados
- 2. Proceso de revisión
- 3. Determinación de los pasos siguientes

#### 1. Evaluación de los resultados

Debe registrar su evaluación, indicando si los resultados de minería de datos cumplen sus criterios de rendimiento comercial. Considere las siguientes cuestiones en su informe:

 ¿Sus resultados se expresan con claridad y de forma que se puedan presentar con facilidad?



#### 1. Evaluación de los resultados (cont)

- ¿Ha realizado descubrimientos especiales o particularmente relevantes que deba resaltar?
- ¿Puede evaluar los modelos y descubrimientos en función de su capacidad de poderse aplicar a los objetivos comerciales?
- En general, ¿en qué medida estos resultados se adaptan a los objetivos comerciales de su organización?
- ¿Qué cuestiones adicionales generan los resultados?
- ¿Cómo puede formular estas cuestiones en términos comerciales?



#### 2. Proceso de revisión

Las metodologías eficaces suelen incluir tiempo para reflexionar sobre los aciertos y errores del proceso que se acaba de completar. Es necesario hacer una revisión de cada fase del modelo CRISP-DM para evitar algún tipo de error que se haya arrastrado a las siguientes fases.

Se recomienda hacer las siguientes preguntas para cada fase:

- ¿Esta fase ha contribuido al valor de sus resultados finales?
- ¿Existen formas de simplificar o mejorar esta fase u operación particular?
- ¿Cuáles fueron los fallos o errores cometidos en esa fase? ¿Cómo se pueden evitar la próxima vez?



#### 2. Proceso de revisión

- ¿Hay callejones sin salida, como modelos específicos que no ofrecen ningún resultado?¿Existen formas de predecir esos callejones sin salida, de forma que los esfuerzos se puedan dirigir con más productividad?
- ¿Se han producido sorpresas (buenas y malas) en esta fase? A posteriori, ¿existe alguna forma de predecir esas instancias?
- ¿Existen decisiones alternativas o estrategias que se puedan utilizar en una fase concreta?

Registre esas alternativas para utilizarlas en proyectos de minería de datos futuros.



#### 3. Determinación de los pasos siguientes

En términos de objetivos comerciales de minería de datos, básicamente, dispone de dos opciones:

- Continuar con la fase de desarrollo. La siguiente fase le ayudará a incorporar los resultados del modelo a su proceso comercial y producir un informe final. Incluso, si sus esfuerzos invertidos en la minería de datos no han sido satisfactorios, debe utilizar la fase de desarrollo de CRISP-DM, para crear un informe final para su distribución al patrocinador del proyecto.
- Volver y refinar o sustituir los modelos. Si encuentra que los resultados son casi óptimos, pero no lo suficiente, considere otro tipo de modelado. Puede utilizar sus conocimientos adquiridos en esta fase, para refinar los modelos y producir mejores resultados.

# f. Implantación

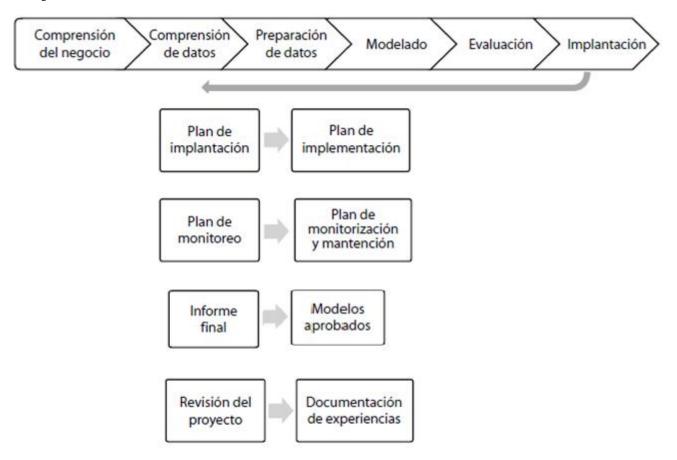


Figura Fase de implementación. Tomado de CRISP-DM 1.0 Step-by-Step Data Mining Guide (P. Chapman et al.), 2000.



La distribución es el proceso que consiste en utilizar sus nuevos conocimientos para implementar las mejoras o modificaciones en su organización.

Esta etapa se conforma de los siguientes pasos:

- 1. Planificación de implantación o distribución
- 2. Planificación del control y el mantenimiento
- 3. Creación de un informe final
- 4. Revisión final del proyecto



#### 1. Planificación de implantación o distribución

Aunque pueda estar ansioso por compartir el fruto de sus esfuerzos en minería de datos, dedique un tiempo a planificar una distribución completa y precisa de los resultados.

- Resumir los resultados, modelos y descubrimientos
- Considere cómo controlará la distribución
  - ¿Cómo se actualizará un modelo distribuido?
  - ¿Cómo decidirá el momento en que el modelo ya no es aplicable?
- Identifique los problemas de distribución y realice un plan de contingencia



#### 2. Planificación del control y del mantenimiento

- ¿Cómo se determina que un modelo ha "expirado"?
- ¿Qué ocurre cuando un modelo expira?
- ¿Puede reconstruir el modelo con nuevos datos o tiene que realizar algunas modificaciones?

En este punto se hace indispensable disponer de documentación suficiente, para valorar el propósito comercial de cada proyecto de minería de datos.



#### 3. Creación de un informe final

El informe debe incluir los siguientes elementos:

- Una descripción detallada del problema original
- El procedimiento utilizado para realizar el proyecto de minería de datos
- El costo del proyecto
- Un resumen de los resultados de minería de datos, incluyendo los modelos y los descubrimientos



#### 4. Revisión final del proyecto

Es el paso final del método CRISP-DM.

Aspectos a incluir en la revisión del proyecto final:

- ¿Cuál es su impresión global del proyecto?
- ¿Qué conocimientos ha adquirido durante el proceso de minería de datos en general y los datos disponibles?
- ¿Qué partes del proyecto han funcionado correctamente? ¿Dónde han surgido las dificultades?
- ¿Existe algún tipo de información que le podría haber evitado confusiones?



# **CRISP-DM:** Fases

#### Comprensión del negocio:

- Entendimiento de los objetivos y requerimientos del proyecto.
- Definición del problema de Minería de Datos

#### 2. Comprensión de los datos

- Obtención conjunto inicial de datos.
- Exploración del conjunto de datos.
- Identificar las características de calidad de los datos
- ✓ Identificar los resultados iniciales obvios.

#### 3. Preparación de Datos

- ✓ Selección de datos
- ✓ Limpieza de datos

#### 4. Modelamiento

Implementación en herramientas de Minería de Datos

#### 5. Evaluación

- ✓ Determinar si los resultados coinciden con los objetivos del negocio
- ✓ Identificar las temas de negocio que deberían haberse abordado

#### 6. Despliegue

- Instalar los modelos resultantes en la práctica
- ✓ Configuración para minería de datos de forma repetida ó continua.



# Fases y Actividades

#### Comprensión del Negocio

#### \*Determinar los Objetivos del Negocio

- ✓ Antecedentes
- √ Objetivos del Negocio
- Negocio
- ✓ Criterio de Éxito
- Evaluar la situación
- ✓ Inventario de requerimientos de Recursos, Hipótesis y
- Limitaciones ✓ Riesgos v
- Contingencias
- ✓ Terminología
- ✓ Costos y Beneficios
- Determinar el objetivo de Minería de Datos
- ✓ Objetivos de Minería de Datos
- ✓ Criterio de Éxito de Minería de Datos
- Desarrollar el Plan de Proyecto
- ✓ Plan de proyecto

#### Comprensión de Datos

#### \*Obtener los datos iniciales

- ✓ Reporte de la obtención de los datos iniciales
- · Describir los Datos
- ✓ Reporte con la descripción de los datos
- Explorar de Datos
   ✓ Reporte de la
- Exploración de Datos
- Verificar de la calidad de los Datos
- ✓ Reporte de la calidad de los datos

#### Preparación de Datos

- Conjunto de Datos
- Descripción de los Datos
- Seleccionar los Datos
- √ Justificación de la inclusión / Exclusión
- Limpiar Datos
- ✓ Reporte de Limpieza de Datos
- Construir Datos
- ✓ Atributos Derivados
- √ Registros
  Generados
- Integrar Datos
- ✓ Datos Combinados
- Dar formato a los Datos
- ✓ Datos Formateados

#### Modelamiento

- 'Seleccionar Técnica de
- Modelamiento ✓ Técnica de
- Modelamiento
- ✓ Modelamiento
- √ Hipótesis
- Generar el Diseño de
- Prueba
- ✓ Diseño de Prueba
- Construir el
   Modelo
- ✓ Configuración de los parámetros del Modelo
- ✓ Descripción del Modelo
- Evaluar el Modelo
- ✓ Evaluación del Modelo
- ✓ Revisión de la configuración de los parámetros del modelo

#### Evaluación

- Evaluar
   Resultados
- √ Hipótesis de 
  Minería de Datos
- √ Resultados
- √ Criterio de éxito del negocio
- ✓ Modelos aprobados
- Revisar el
- Proceso
- √ Revisión del Proceso
- Determinar los siguientes pasos
- ✓ Lista de Posibles Acciones
- ✓ Decisión

#### Despliegue

- Desplegar el Plan
- ✓ Plan de Despliegue
- Monitorear y Mantener
- ✓ Plan de monitoreo y Mantenimiento
- Desarrollar el reporte final
- ✓ Reporte Final
- ✓ Presentación Final
- \*Revisión del Provecto
- ✓ Documentación
- de las experiencias

# Referencias

# **Contacto**

# Carlos Alberto González Martínez

Jefe de departamento de correlaciones, cruces y alertas (C5i)

gmcmmiv@hotmail.com