Rodriguez_fitta_jose_emanuel_Practica2

March 1, 2022

1 Práctica 2

El conjunto de datos 'Birthweight' contiene la información de 42 bebés al nacer. La pregunta de investigación es saber si existe una relación entre al peso al nacer y el tiempo de gestación. La variable dependiente es Peso al nacer (dada en libras) y la variable independiente para esta actividad es la edad gestacional del bebé al nacer (en semanas).

[4]:
```
# Librería para análisis de datos
import pandas as pd
import numpy as np

# Librerías para gráficos
import matplotlib.pyplot as plt
import seaborn as sns

# Librerías para Preprocesado y modelo
from scipy.stats import pearsonr
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score
from sklearn.metrics import mean_squared_error
import statsmodels.api as sm
import statsmodels.formula.api as smf
from statistics import mode
```

[5]:
```
df = pd.read_csv('https://raw.githubusercontent.com/rbarcenas/CD_M3_Notebooks/
↪main/Birthweight.csv')
df.head(5)
```

[5]:

	ID	Gestation	Birthweight
0	1	44	4.55
1	2	40	4.32
2	3	41	4.10
3	4	44	4.07
4	5	42	3.94

[6]:
```
df.drop('ID', axis = 1, inplace = True)
df.head(5)
```

[6]:

	Gestation	Birthweight
0	44	4.55
1	40	4.32
2	41	4.10
3	44	4.07
4	42	3.94

a) Realiza una descripción gráfica y de medidas estadísticas (descriptivas) de los datos.

[7]:
```
df.describe()
```

[7]:

	Gestation	Birthweight
count	42.000000	42.000000
mean	39.190476	3.312857
std	2.643336	0.603895
min	33.000000	1.920000
25%	38.000000	2.940000
50%	39.500000	3.295000
75%	41.000000	3.647500
max	45.000000	4.570000

[19]:
```
for column in df.columns:
  plt.figure(figsize = (10, 5))
  df[column].hist(bins = 10)
  plt.axvline( df[column].mean(), color = 'r', label = 'Media = {}'.
↪format(round(df[column].mean(), 2)))
  plt.axvline( df[column].median(), color = 'black', label = 'Mediana = {}'.
↪format(round(df[column].median(), 2)))
  plt.axvline( mode(df[column]), color = 'orange', label = 'Moda = {}'.
↪format(round(mode(df[column]), 2)))
  plt.title(str(column))
  plt.legend()
  plt.show()
```

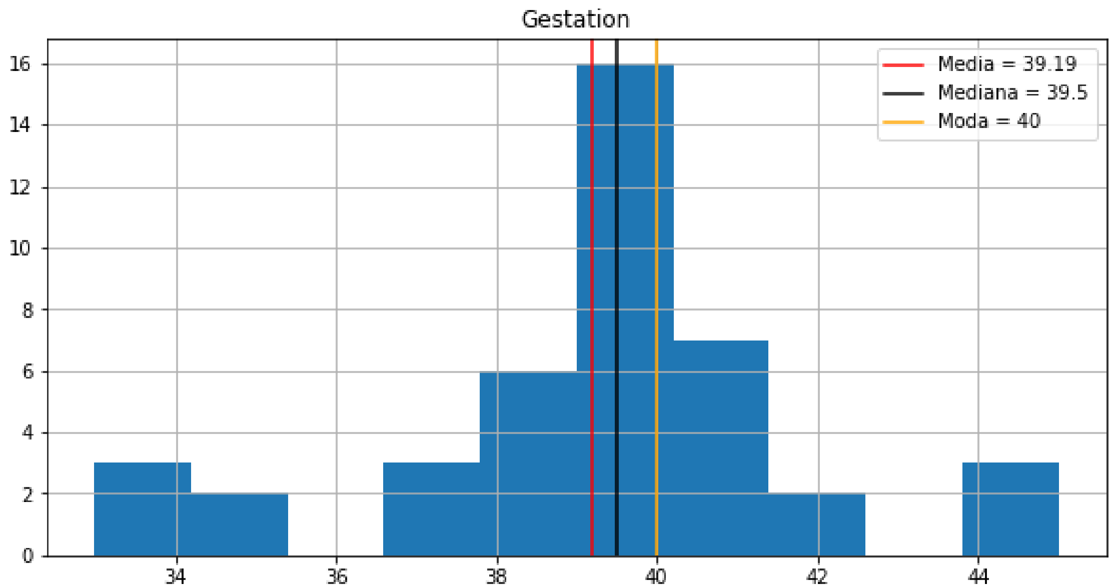

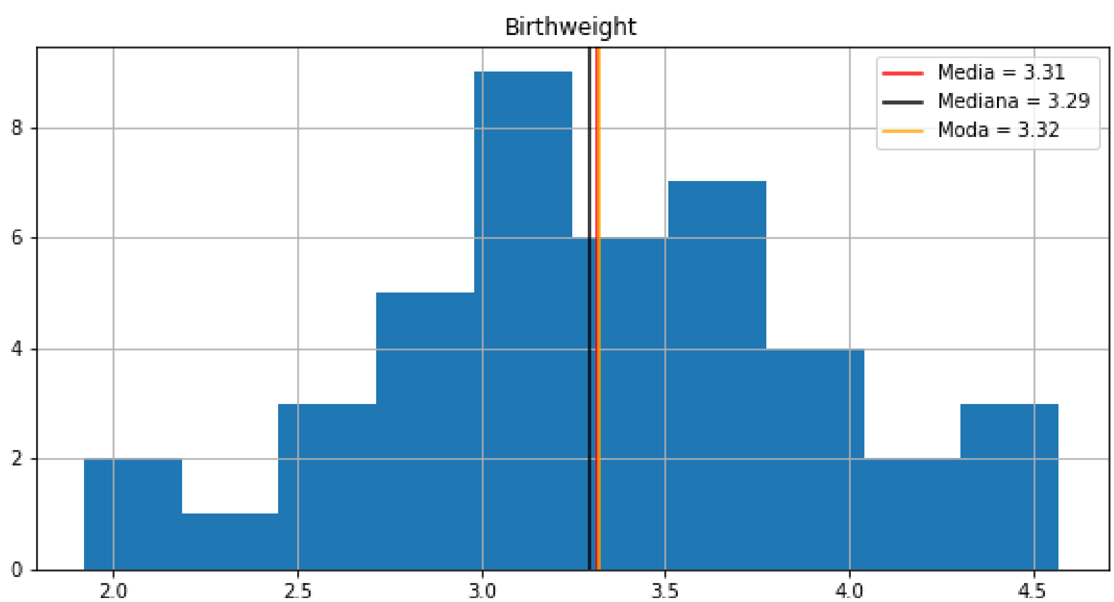

b) Realiza un análisis de regresión lineal y proporcionar estimadores puntuales de los parámetros.

[21]:
```
fig, ax = plt.subplots(figsize=(6, 3.84))

df.plot(
    x    = df.columns[0],
    y    = df.columns[1],
```

```
    c    = 'firebrick',
    kind = "scatter",
    ax   = ax
)
plt.xlabel('Gestation (semanas)')
plt.ylabel('Birthweight (libras)')
ax.set_title('Representación de {} vs. {}'.format(df.columns[1], df.
 ↪columns[0]));
```

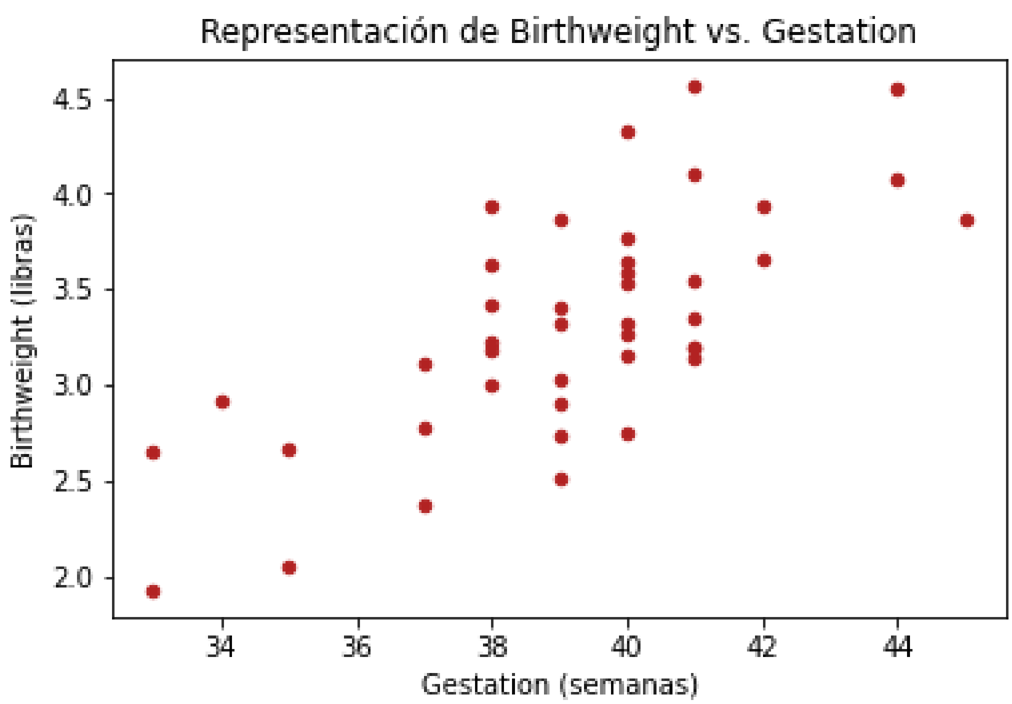

[10]:
```
X = df[['Gestation']].values.reshape(-1, 1)
y = df['Birthweight'].values.reshape(-1, 1)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2)
```

[11]:
```
datos_train = pd.DataFrame(np.hstack((X_train, y_train)), columns =␣
 ↪['Gestation', 'Birthweight'])
modelo = smf.ols(formula = 'Birthweight ~Gestation', data = datos_train)
modelo = modelo.fit()
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:            Birthweight   R-squared:                       0.483
```

```
Model:                            OLS   Adj. R-squared:                  0.467
Method:                 Least Squares   F-statistic:                     29.01
Date:                Tue, 01 Mar 2022   Prob (F-statistic):           7.09e-06
Time:                        05:50:02   Log-Likelihood:                -17.940
No. Observations:                  33   AIC:                             39.88
Df Residuals:                      31   BIC:                             42.87
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     -2.7845      1.130     -2.465      0.019      -5.088      -0.481
Gestation      0.1558      0.029      5.386      0.000       0.097       0.215
==============================================================================
Omnibus:                        0.923   Durbin-Watson:                   1.298
Prob(Omnibus):                  0.630   Jarque-Bera (JB):                0.957
Skew:                           0.301   Prob(JB):                        0.620
Kurtosis:                       2.422   Cond. No.                         590.
==============================================================================

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

Modelo ajustado:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \hat{x} = -2.9689 + 0.1598\hat{x}$$

[25]:

```python
fig, ax = plt.subplots(figsize=(8,6))
ax.plot(df['Gestation'] , df['Birthweight'] , 'o', label="Datos")
ax.plot(X_train, modelo.fittedvalues, 'r', label="Ajustado")
legend = ax.legend(loc="best")
plt.xlabel('Gestation (semanas)')
plt.ylabel('Birthweight (libras)')
plt.title('Diagrama de dispersión con la recta del modelo ajustado');
```

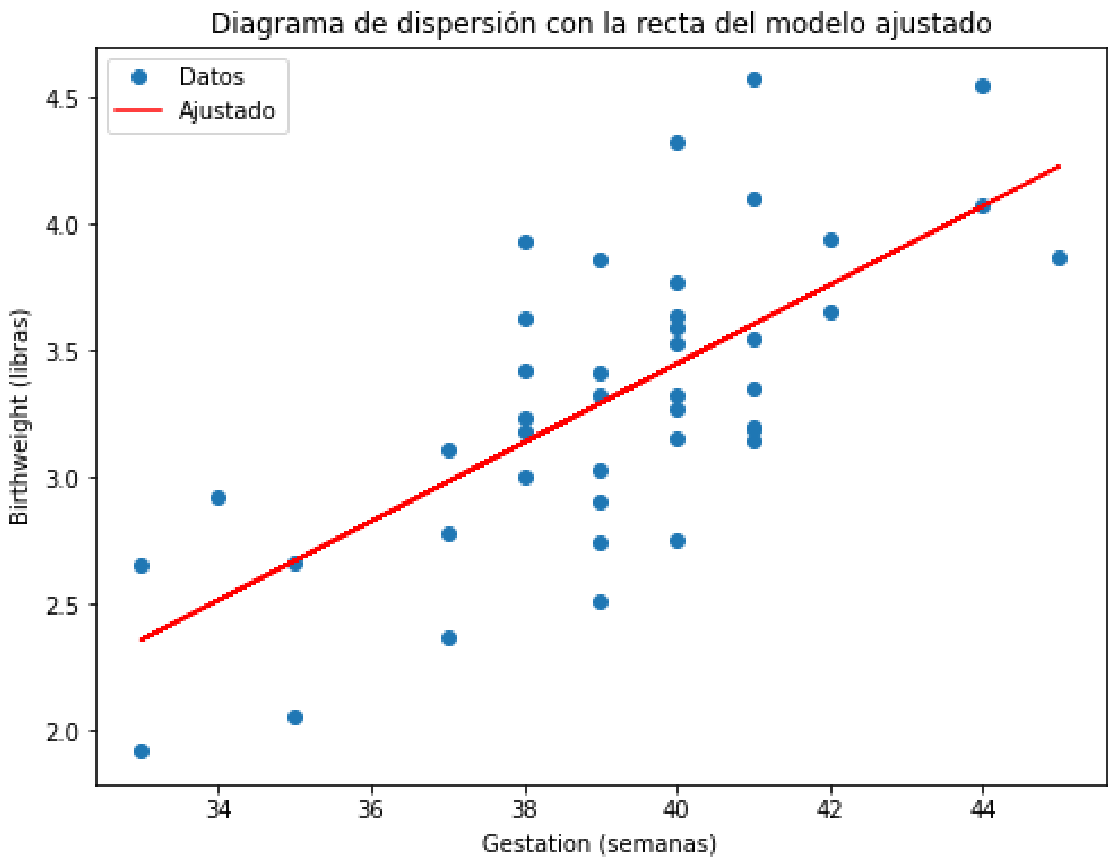

c) Usando el error estándar, establece intervalos de confianza al 95% para los parámetros de la regresión.

[13]:
```python
parametros = modelo.conf_int(alpha = 0.05)
```

[14]:
```python
parametros.rename(index = {'Intercept':'Beta 0', 'Gestation':'Beta 1'},
                  columns = {0: 'Extremo_inferior', 1: 'Extremo_Superior'},␣
 ↪inplace=True)
```

Losintervalos de confianza al 95% para los parámetros de la regresión son

[15]:
```python
parametros
```

[15]:

	Extremo_inferior	Extremo_Superior
Beta 0	-5.088459	-0.480521
Beta 1	0.096807	0.214792

d) Realiza las pruebas de hipótesis para los parámetros y para determinar la significancia de la regresión.

1.0.1 Parámetro β_0

1. $H_0 : \beta_0 = 0$ vs. $H_1 : \beta_0 \neq 0$
2. Estadística de prueba $t = \frac{\hat{\beta}_j}{se(\hat{\beta}_j)} \sim t_{n-2}$. En particular, tenemos que para β_0, $t^* = -2.465$.
3. Para un nivel de significancia $\alpha = 0.05$, la regla de decisión es: Rechazar H_0 si

- Sucede que

$$|t^*| \geq t_{1-\alpha/2,n-2} = 2.05$$

, o

- $p-$valor $= P(t_{1-\alpha/2,n-2} > |t^*|) \leq \alpha = 0.05$

4. Conclusión: Dado que $|t^*| = 2.465 > 2.05$ y el $p-$valor $= 0.019 < 0.05$, la decisión es rechazar la hipótesis nula H_0 con un nivel de significancia del 5%

1.0.2 Parámetro β_1

1. $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$
2. Estadística de prueba $t = \frac{\hat{\beta}_j}{se(\hat{\beta}_j)} \sim t_{n-2}$. En particular, tenemos que para β_1, $t^* = 5.386$.
3. Para un nivel de significancia $\alpha = 0.05$, la regla de decisión es: Rechazar H_0 si

- Sucede que

$$|t^*| \geq t_{1-\alpha/2,n-2} = 2.05$$

, o

- $p-$valor $= P(t_{1-\alpha/2,n-2} > |t^*|) \leq \alpha = 0.05$

4. Conclusión: Dado que $|t^*| = 5.386 > 2.05$ y el $p-$valor $= 0.000 < 0.05$, la decisión es rechazar la hipótesis nula H_0 con un nivel de significancia del 5%

1.0.3 ANOVA: Significancia de la regresión

1. $H_0 : \beta_j = 0, \forall j$ vs $H_1 : \beta_j \neq 0$, para alguna j
2. Estadística de prueba

$$F = \frac{SCR}{SCE/(n-2)} \sim F_{1,n-2}$$

   En particular, tenemor que $F^* = 29.01$.
3. Para un nivel de significancia $\alpha = 0.05$, la regla de decisión es: Rechazar H_0 si

- Sucede que $F^* > F^{1-\alpha}_{1,n-2} = 4.196$, o
- $p -$ valor $= P(F^{1-\alpha}_{1,n-2} > F*) \leq \alpha = 0.05$.

4. Conclusión: Como $F^* = 29.01 > 4.196$ y además, $p -$ valor $= 7.09 \times 10^{-6} < 0.05$. Se rechaza la hipótesis nula H_0 con un nivel de significancia del 5%.

e) Con base en tu análisis, concluye sobre el contexto del problema y responde la pregunta de investigación

Debido a que se rechazaron en todos los casos las hipótesis nulas respectivas podemos concluir que si existe una relación entre el peso al nacer y el tiempo de gestación.